

DÉTECTION ET RECONNAISSANCE DE GAMMARES

Arthur Mourgue

Maxime Faure

Chaymae Ouzougagh

INSA Lyon

1. INTRODUCTION

Initié par le laboratoire Biomae [1], ce projet s'inscrit dans le cadre de la biosurveillance des écosystèmes aquatiques, où le gammare est exploité comme bio-indicateur pour l'évaluation de la contamination chimique et toxique.

Pour automatiser le tri manuel actuel, un prototype capture deux vues orthogonales synchronisées des gammares en mouvement. La limitation de l'intensité lumineuse, imposée pour la survie des spécimens, engendre un flou de mouvement qui s'ajoute à une forte variabilité d'observation. L'objectif est de proposer une solution logicielle pour automatiser la classification en trois catégories (mâle, femelle, couple) et estimer la maturité des individus.

La base de données annotée étant limitée en quantité, l'approche choisie doit garantir une convergence efficace avec un faible nombre d'exemples. Cette contrainte impose le recours à une augmentation de données réaliste (simulation de flou, rotations) pour pallier le manque d'échantillons et prévenir le sur-apprentissage [2].

Compte tenu de la faible taille des gammares dans l'image globale, l'extraction de la zone d'intérêt (recadrage) est indispensable. L'état de l'art confirme que cette étape de localisation préalable maximise les performances de classification fine [3, 4].

Pour réaliser ce recadrage, une détection préalable est nécessaire. L'état de l'art oppose trois architectures dominantes : les Transformers (DETR) [5], les détecteurs à deux étapes (Faster R-CNN) et ceux à étape unique (YOLO). Bien que performant grâce à son mécanisme d'attention, DETR souffre d'une convergence lente et de difficultés notoires sur les petits objets en l'absence de vastes datasets [6]. Faster R-CNN reste une référence en précision, notamment en milieu sous-marin, mais sa latence et son coût élevé dessert les contraintes embarquées [7]. À l'inverse, YOLO (You Only Look Once) est retenu pour sa capacité à converger efficacement avec une base de données réduite pour une précision équivalente aux Transformers [8].

Pour la classification des images recadrées, le choix de l'architecture résulte d'un compromis entre la précision maximale théorique et les contraintes de latence et d'embarquabilité. Si des modèles récents comme EfficientNetV2 ou ConvNeXt dominent les benchmarks académiques en termes de précision pure, leur coût de calcul reste élevé pour un gain de précision

faible [9]. Dans cette optique, MobileNetV3 est retenu comme le standard industriel pour l'inférence légère, offrant le meilleur rapport performance/efficacité [10]. Concernant les classes, traiter la catégorie "Indéterminé" comme une mesure d'incertitude (rejet) plutôt que comme un morphotype biologique peut permettre d'avoir de meilleurs résultats [11].

L'estimation de la maturité reposant sur la taille et la courbure, la modélisation de la pose est critique. Une première approche géométrique segmente la silhouette par seuillage d'Otsu [12] et extrait son axe longitudinal par ACP sur les points du contour. La longueur du spécimen est alors déterminée en projetant les extrémités du contour sur cet axe, en privilégiant la vue la moins courbée pour minimiser l'erreur de mesure. Cependant, pour accroître la robustesse face aux déformations complexes, l'état de l'art privilégie des workflows dédiés comme DeepLabCut [13] ou SLEAP [14]. Ces outils offrent une flexibilité supérieure aux modèles génériques (YOLO-Pose) pour les squelettes animaux [15], au prix d'un effort d'annotation accru.

Pour corriger le flou de mouvement, les approches par apprentissage profond dominent désormais les algorithmes classiques (Wiener). L'état de l'art [16] se structure autour de trois architectures principales : les réseaux génératifs (GANs), les Transformers (Restormer) et les CNNs. Le choix s'est porté sur NAFNet [17], une architecture CNN. Ce modèle est retenu pour son excellent ratio performance/efficacité, permettant une restauration fidèle des détails sans le coût de calcul élevé des Transformers.

2. MÉTHODE

Cette section présente le pipeline de détection et de classification automatique de gammares à partir de deux vues synchronisées (Fig. 1), conçu pour un dataset limité et des images parfois dégradées (flou de mouvement).

En amont, les données sont augmentées. Le pipeline comprend ensuite la détection et le découpage des régions d'intérêt, le défloutage, puis l'estimation de la pose et la classification. Enfin, les prédictions des deux vues sont fusionnées pour produire la décision finale.




Fig. 1. Pipeline d’analyse et de décision des gammarès

2.1. Images, augmentation d’images et defloutage

Le jeu de données initial est limité (214 échantillons) et fortement déséquilibré (114 indéterminés, 55 mâles, 25 femelles, 20 couples), ce qui augmente le risque de sur-apprentissage et réduit la capacité de généralisation.[18, 19, 20, 21]

Un défloutage est appliqué aux images dégradées afin de restaurer des détails morphologiques suffisants pour permettre une ré-annotation manuelle et réinjecter ces exemples dans l’apprentissage.[16, 17]

Pour améliorer la généralisation des réseaux, trois approches d’augmentation d’images sont appliquées: des transformations géométriques (mise à l’échelle, découpage, translations, rotations)[22], des perturbations des intensités (variations de luminosité/contraste, flou directionnel, flou gaussien, bruit gaussien), et complétées par des approches Mosaic et MixUp [23, 24] dans des plages de valeurs réalistes.

2.2. Détection et extraction des régions d’intérêt

Les images brutes contiennent une proportion importante de fond non informatif. Une étape de détection est donc appliquée pour localiser les gammarès afin d’extraire des régions d’intérêt destinées à la découpe, au défloutage puis à la classification. Le détecteur est entraîné par apprentissage par transfert à partir de poids pré-entraînés.[25, 26]

La détection repose sur YOLO, qui traite la détection comme un problème de régression et prédit en une seule passe des boîtes englobantes et des probabilités de classe, ce qui permet une inférence rapide.[27] Une version récente légère, YOLO11n (Nano), est retenue pour limiter le sur-

apprentissage et assurer une inférence rapide.[28] L’architecture comprend un backbone convolutionnel (extraction de caractéristiques), un neck de fusion multi-résolution (agrégation multi-échelle) et une tête de détection opérant à plusieurs échelles.[29]

2.3. Classification, fusion et décision

La classification sur les régions d’intérêt extraites est réalisée selon trois classes : mâle, femelle, couple. Un classifieur convolutionnel de type MobileNetV3 est retenu en raison de sa compacité et de son efficacité, en particulier lorsque les données annotées sont limitées.[10, 19, 20]

Compte tenu du faible volume d’annotations, l’apprentissage suit une stratégie en deux étapes. Dans un premier temps, le backbone est gelé et seule la tête de classification est entraînée afin de stabiliser l’optimisation et de limiter le sur-apprentissage.

Dans un second temps, les dernières couches du réseau sont dégelées et affinées par fine-tuning avec un faible taux d’apprentissage, permettant d’adapter les représentations aux caractéristiques morphologiques des gammarès.[26, 30]

Les prédictions issues des deux caméras sont ensuite combinées par une fusion tardive reposant sur un MLP, qui agrège les scores de classification pour produire la décision finale.

2.4. Estimation de la pose

En parallèle de la classification, les régions d’intérêt sont traitées pour l’estimation de la pose. Une approche géométrique légère (segmentation/ACP) est d’abord appliquée pour comparer les courbures et sélectionner la vue la plus rectiligne parmi la paire synchronisée. La morphométrie précise est ensuite extraite de cette vue optimale via un modèle de pose par apprentissage (type SLEAP ou YOLO-Pose), entraîné à localiser les points-clés anatomiques minimaux (tête, centre, queue).

2.5. Critères d’évaluation et métriques de performance

Les performances sont évaluées pour la détection, la classification et la décision finale.

En détection, l’IoU mesure le recouvrement entre la boîte prédite et la vérité terrain, et l’AP (AP@0.5 et mAP@[0.5:0.95]) résume la performance précision-rappel [31, 32].

En classification, l’accuracy est la proportion de prédictions correctes, la précision la fiabilité des positifs prédits, le rappel la proportion de positifs retrouvés, et le F1-score la synthèse précision-rappel (macro-F1 pour gérer le déséquilibre), complétés par une matrice de confusion [33].

Pour la décision finale, la sortie du MLP fournit une classe et une confiance. Une décision n’est acceptée que si cette confiance est supérieure ou égale à 95%, sinon l’individu est renvoyé vers le bassin. Le taux de rejet correspond à la proportion d’individus non classés car sous ce seuil.

3. EXPÉRIMENTATIONS

Cette section expose les résultats obtenus sur un jeu de données complexe caractérisé par du flou de mouvement et des occlusions.

3.1. Détection et localisation

Le jeu de données initial de 214 images est réparti entre 172 images pour l'entraînement (80%) et 42 pour la validation (20%). Les classes étudiées regroupent Mâle (M), Femelle (F), Indéterminé (I), Couple (C) et Gammare (G).

Une première comparaison oppose l'architecture D-FINE (Transformer) à YOLOv11 (CNN). Le Tableau 1 met en évidence la difficulté du Transformer à apprendre sur un volume de données restreint tandis que le CNN tire profit de ses convolutions.

Table 1. Comparaison des architectures.

Architecture	Modèle	mAP_{50}	mAP_{50-95}
Transformer	D-FINE-S	0.440	0.234
CNN	YOLOv11-N	0.850	0.564

L'impact de la détection multi-classes par rapport à une classe unique est ensuite analysé. Le Tableau 2 compare la détection de 3 classes (M, F, I) face à une classe unique (G). La simplification de la tâche favorise nettement le modèle car la recherche d'une entité unique Gammare permet d'atteindre une détection quasi-parfaite avec un mAP_{50} de 0.991. Cette méthode est retenue pour la suite.

Table 2. Impact du nombre de classes sur la détection.

Stratégie	Classes	mAP_{50}	mAP_{50-95}
3 Classes	M, F, I	0.774	0.484
2 Classes	M, F	0.850	0.564
1 Classe	G	0.991	0.556

3.2. Classification et reconnaissance

L'étape suivante consiste à classer les images découpé en Mâle, Femelle, Indéterminé ou Couple. L'insuffisance des 214 images initiales a motivé l'ajout de données issues d'une nouvelle campagne et du défloutage pour atteindre un total de 484 images comme détaillé dans le Tableau 3.

Table 3. Évolution du jeu de données.

Classe	Base + Ajout	Train Final	Val Final
Mâle	55 + 123 = 178	155	23
Femelle	25 + 147 = 172	152	20
Indéterminé	114 + 0 = 114	89	25
Couple	20 + 0 = 20	17	3
Total	214 + 270 = 484	413	71

Différentes stratégies présentées dans le Tableau 4 ont été évaluées. Les tests sur la base initiale de 214 images montrent que le modèle à 2 classes peine à identifier les femelles

en raison du déséquilibre des données en faveur des mâles. L'intégration de la classe Indéterminé diminue la précision globale mais renforce la fiabilité en filtrant les images de qualité insuffisante.

Table 4. Performances selon la stratégie.

Stratégie	Données	Classes	Acc.	F1
2 Classes	214 img	M, F	0.83	0.78
3 Classes	214 img	M, F, I	0.74	0.70
4 Classes	214 img	M, F, I, C	0.63	0.60
4 Classes	484 img	M, F, I, C	0.90	0.92

L'augmentation du volume de données s'avère déterminante puisque le modèle à 4 classes passe d'une précision de 63% à 90%. L'examen de la matrice de confusion du modèle final révèle une détection intégrale des couples avec un score parfait. Ce résultat sur les couples doit toutefois être considéré avec prudence car il ne repose que sur 3 images de validation ce qui souligne la sous-représentation de cette classe. La classe Indéterminé remplit par ailleurs son rôle en capturant efficacement les cas ambigus.

3.3. Défloutage

L'absence de paires réelles Flou/Net impose la création d'un jeu de données semi-synthétique. Celui-ci est constitué de 224 images nettes de référence, systématiquement recadrées en 512×512 pixels.

Les images d'entrée flou sont générées via Albumentations [34] en simulant du flou de mouvement.

Un modèle NAFNet basé sur dataset GoPro est fine-tuné sur cette nouvelle base de données. L'entraînement est conduit sur 10 000 itérations (AdamW, $LR = 2 \times 10^{-4}$). La fonction de coût L1 est privilégiée à la MSE car elle favorise la conservation des hautes fréquences (gain de netteté).

La qualité de restauration est mesurée par le PSNR et le SSIM, calculés exclusivement sur les pixels réels de l'image. Le Tableau 5 compare notre approche fine-tunée face à un filtre classique (*Unsharp Mask*) et à l'état de l'art.

Table 5. Comparaison quantitative des méthodes de restauration (calculé sur la ROI).

Méthode	PSNR (dB)	SSIM
Unsharp Mask	23.16	0.88
NAFNet (GoPro)	29.82	0.94
NAFNet Finetuné	31.44	0.95

Le modèle finetuné surpasse l'état de l'art générique de 1.62 dB et la méthode classique de 8.28 dB. Si le modèle GoPro offre un piqué visuel qui peut être plus flatteur, le modèle fine-tuné favorise la reconstruction de la structure géométrique.

Une étude d'ablation (Tab. 6) quantifie l'apport du module de défloutage sur la décision finale. L'application




Fig. 2. Comparaison de la restauration sur une région d'intérêt. Les scores indiqués sont (PSNR / SSIM).

systématique du défloutage s'avère contre-productive, entraînant une chute du F1-score de 0.92 à 0.80. Ce résultat s'explique par le *domain shift* : les artefacts de lissage générés par NAFNet sur des images déjà nettes perturbent les caractéristiques apprises par le classifieur sur les données brutes.

Table 6. Impact des stratégies de défloutage sur les performances (Accuracy et F1-Score).

Images traitées	Défloutage	Acc.	F1
Toutes	Sans	0.90	0.92
	Avec	0.78	0.80
Ciblé (Indéterminés)	Avec	0.92	0.93
Synthétique (Flou fort)	Sans	0.46	0.55
	Avec	0.60	0.64

La stratégie hybride conditionnelle (activation uniquement sur la classe "Indéterminé") permet d'améliorer la capacité de classification. Face à un flou synthétique intense, le module permet de rehausser l'accuracy de 0.46 à 0.60 et le F1-score de 0.55 à 0.64, validant sa capacité à améliorer la classification dans des cas extrêmes.

3.4. Estimation de la pose et comparaison des méthodes

Deux approches ont été évaluées pour l'estimation de la pose: **YOLO-Pose** repose sur une approche intégrée combinant la détection et la régression directe des points clés au sein d'un même réseau, **DeepLabCut** constitue quant à lui une approche spécialisée de régression de points clés, pour laquelle les annotations au format COCO ont été converties vers le format DeepLabCut. Sept points clés sont définis par individu : *head*, *thorax1*, *thorax2*, *thorax3*, *abdomen1*, *abdomen2*, *tail*. Les performances sont évaluées sur un même sous-ensemble d'images de test, et du même script d'évaluation partagé par les deux méthodes, en s'appuyant sur les métriques suivantes : l'erreur quadratique moyenne (MSE) calculée sur les coordonnées des points clés (en pixels²), ainsi que le PSNR et le SSIM, obtenus à partir de masques de pose générés à partir des annotations de référence, ces métriques sont calculées image par image puis moyennées sur l'ensemble de test.

Les résultats montrent que DeepLabCut obtient une erreur quadratique moyenne plus faible, traduisant une meilleure

Table 7. Comparaison des méthodes d'estimation de pose

Méthode	Nb points	MSE ↓	PSNR ↑	SSIM ↑
YOLO-Pose	7	18663.6	25.65	0.9918
DeepLabCut	7	8117.5	25.07	0.9902

précision spatiale des points clés. À l'inverse, YOLO-Pose présente des scores PSNR et SSIM légèrement supérieurs, indiquant une meilleure cohérence structurelle globale de la pose estimée. La Fig. 3 présente des exemples représentatifs



Fig. 3. Poses estimées par YOLO-Pose (gauche) et DeepLabCut (droite) sur une même image de test.

de poses estimées par YOLO-Pose et DeepLabCut sur les mêmes images de test. Les superpositions indiquent que DeepLabCut localise plus précisément certains points centraux, tandis que YOLO-Pose génère des poses globalement régulières. Des tests à quatre points sur images recadrées n'ont pas amélioré les performances, la réduction du squelette pénalisant le PSNR et le SSIM.

4. CONCLUSION

Ce travail présente un pipeline pour la détection, le défloutage, la classification et l'estimation de la pose de gammarus dans des conditions réalistes. Les résultats montrent l'efficacité de YOLO pour la détection et la robustesse de MobileNetV3 pour la classification sur un jeu de données limité. L'estimation de la pose complète la classification par des informations morphologiques, ouvrant la voie à l'automatisation du tri en biosurveillance.

5. REFERENCES

- [1] Biomae, “Biomae: Laboratoire de biosurveillance des milieux aquatiques,” <https://biomae.fr/>, Accessed: 2025-12-18.
- [2] Connor Shorten and Taghi M. Khoshgoftaar, “A survey on image data augmentation for deep learning,” *Journal of Big Data*, vol. 6, no. 1, pp. 60, 2019.
- [3] Harald Hanselmann and Hermann Ney, “ELoPE: Fine-grained visual classification with efficient localization, pooling and embedding,” in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2020, pp. 1827–1836.
- [4] Xiu-Shen Wei, Jian-Wei Wu, and Quan-Sen Sun, “Fine-grained image analysis with deep learning: A survey,” *IET Computer Vision*, vol. 15, no. 2, pp. 77–97, 2021.
- [5] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko, “End-to-end object detection with transformers,” in *European Conference on Computer Vision (ECCV)*, 2020, pp. 213–229.
- [6] X. Li et al., “A survey on transformer-based object detection,” *ACM Computing Surveys*, 2025.
- [7] W. Sahu et al., “Deep learning approaches for underwater object detection: A review,” *International Research Journal of Modernization in Engineering Technology and Science (IRJMS)*, 2025.
- [8] A. Pratama and A. Z. Arifin, “Performance analysis of object detection models: Yolov11, yolov8, faster rcnn, and detr,” *Journal of Applied Intelligent Computing (JAIC)*, vol. 8, no. 2, 2024.
- [9] Mingxing Tan and Quoc Le, “Efficientnetv2: Smaller models and faster training,” in *International Conference on Machine Learning (ICML)*, 2021, pp. 10096–10106.
- [10] Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, et al., “Searching for mobilenetv3,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 1314–1324.
- [11] Moloud Abdar, Farhad Pourpanah, Sadiq Hussain, et al., “A review of uncertainty quantification in deep learning: Techniques, applications and challenges,” *Information Fusion*, vol. 76, pp. 243–297, 2021.
- [12] Nobuyuki Otsu, “A threshold selection method from gray-level histograms,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, 1979.
- [13] Jessy Lauer, Mu Zhou, Shaokai Ye, et al., “Multi-animal pose estimation, identification and tracking with deeplabcut,” *Nature Methods*, vol. 19, pp. 496–504, 2022.
- [14] Talmo D. Pereira, Nathaniel Tabris, Arie Matsliah, et al., “Sleap: A deep learning system for multi-animal pose tracking,” *Nature Methods*, vol. 19, pp. 486–495, 2022.
- [15] Chen Wang et al., “Deep learning for animal pose estimation: A survey,” in *OpenReview*, 2021.
- [16] Yawen Xiang et al., “Deep learning in motion deblurring: Current status, benchmarks and future prospects,” *arXiv preprint arXiv:2401.05055*, 2024.
- [17] Liangyu Chen, Xiaojie Chu, Xiangyu Zhang, and Jian Sun, “Simple baselines for image restoration,” in *European Conference on Computer Vision (ECCV)*, 2022, pp. 17–33.
- [18] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.
- [19] Lorenzo Brigato and Luca Iocchi, “A close look at deep learning with small data,” *arXiv preprint arXiv:2003.12843*, 2020.
- [20] Ishfaq Hussain Rather, Sushil Kumar, and Amir H. Gandomi, “Breaking the data barrier: A review of deep learning techniques for democratizing ai with small datasets,” *Artificial Intelligence Review*, vol. 57, no. 226, Aug. 2024.
- [21] Christopher M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [22] Alexander Buslaev, Alex Parinov, Eugene Khvedchenya, Vladimir I. Iglovikov, and Alexandr A. Kalinin, “Albumentations: Fast and flexible image augmentations,” *arXiv preprint arXiv:1809.06839*, 2018.
- [23] Ultralytics, “Ultralytics documentation: Data augmentation reference,” <https://docs.ultralytics.com/reference/data/augment/>, Accessed: 2025-12-17.
- [24] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, and David Lopez-Paz, “mixup: Beyond empirical risk minimization,” in *International Conference on Learning Representations (ICLR)*, 2018.
- [25] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton, “Imagenet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2012.

- [26] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson, “How transferable are features in deep neural networks?,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2014.
- [27] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.
- [28] Ultralytics, “Ultralytics yolo11 documentation,” <https://docs.ultralytics.com/models/yolo11/>, Accessed: 2025-12-17.
- [29] Ultralytics, “Object detection architectures,” 2025.
- [30] Keras Team, “Transfer learning and fine-tuning,” 2025.
- [31] Mark Everingham, Luc Van Gool, Christopher K. I. Williams, John Winn, and Andrew Zisserman, “The PASCAL visual object classes (VOC) challenge,” *International Journal of Computer Vision*, vol. 88, no. 2, pp. 303–338, 2010.
- [32] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick, “Microsoft COCO: Common objects in context,” in *Proceedings of the European Conference on Computer Vision (ECCV)*. 2014, pp. 740–755, Springer.
- [33] Marina Sokolova and Guy Lapalme, “A systematic analysis of performance measures for classification tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009.
- [34] Alexander Buslaev, Vladimir I. Iglovikov, Eugene Khvedchenya, Alex Parinov, Mikhail Druzhinin, and Alexandr A. Kalinin, “Albumentations: Fast and flexible image augmentations,” *Information*, vol. 11, no. 2, pp. 125, 2020.